

진행 현황과 구현 목표

2026년 10월 8일 기준 · 팀 공유용 · 함께 보는 문서: 작업명세서(10월 9일)


개발할 AI 서비스를 한 줄로 설명하면, 인공지능기본법과 관련 법령에서 걸리는 조문을 찾아 **빌드 로그처럼** 보여주는 도구입니다. 뼈대(데이터·검색·판정·화면·평가)는 모두 돌아가고, 지금 실력은 처음 보는 케이스 기준 **최종 빌드 정확도 0.61**입니다. 다음 목표는 RAG 설정을 함께 실험해 이 숫자를 올리는 것입니다.

지키는 원칙 세 가지


- LLM은 판정하지 않는다. 서비스 설명에서 사실(활용 영역, 생성형 여부, 생체정보 사용 등)만 뽑는다.
- RAG는 후보를 찾고, 규칙이 판정한다. 검색이 놓친 조문은 판정하지 않으므로 검색 성능이 결과에 그대로 드러난다.
- 모르면 단정하지 않는다. 정보가 부족하면 **REVIEW**로 되묻고, 6종 밖 규정이 필요하면 **EXTERNAL**로 남긴다.

1 어떻게 동작하나

미리 한 번 — 적재 (python -m scripts.ingest)



요청마다 — 법 빌드 (화면의 [법 빌드 실행])



보라색 칸이 RAG 구간입니다. 내일 실험은 적재(점선)와 ② 구간의 설정을 바꿔 가며 진행합니다.

2 지금까지 한 것

6종 원본 PDF (법령·시행령·영문본·해설)	1,736 Chroma에 적재한 청크	152 절 단위로 태깅한 조문 레코드	233 통과한 테스트 (CI 자동 실행)
-------------------------------------	--------------------------------	--------------------------------	----------------------------------

영역	한 일	상태
데이터	법령 6종 원본을 data/raw/에 고정. 판정에 쓰는 조문 152개를 절 단위로 태깅(인공지능기본법 66·시행령 59·신용정보법 11·개인정보 보호법 7·가이드라인 해설 요약 9). 해설 요약은 뺀 143개는 원문 PDF와 글자 단위로 대조하는 테스트가 있음.	완료
PDF 변환·청킹	pypdf에서 Docling으로 전환. 법령은 조·항·호·목, 영문본은 Article 단위로 자름. 문서별 청크: 개인정보 보호법 599·신용정보법 575·인공지능기본법 235·영문본 180·시행령 127·해설 20. 모든 청크에 원본 파일명과 SHA-256 해시를 기록.	완료
BKL 해설	법무법인 태평양 해설 PDF 원문 11개 청크는 Chroma에서 검색할 수 있게 적재하고(판정 검색에는 아직 안 씀), 검수한 요약 9개는 판정용으로 따로 저장. 화면에서는 요약임을 표시.	완료
RAG 검색	설명 그대로(naive) 검색 + 특성을 법률 용어로 바꾼 쿼리(enriched). 쿼리마다 top-5, 참조 그래프 1단계 확장. 메타데이터 필터로 영문본·BKL 원문·정부·위원회가 주어진 조문은 판정 검색에서 제외.	완료

판정	Rule Engine과 상태 7종(MATCH · REQUIRED · CONDITIONAL · SHOULD · REVIEW · OPPORTUNITY · INFO), 되묻기 질문, EXTERNAL 표식, 제재 경로(직접·간접·없음), 개인정보 보호법·신용정보법 연결 판정.	완료
화면	SPEC → BUILD → INSPECT 3단 화면. INSPECT에 "이 항목을 찾은 경로"(검색 쿼리·유사도 / 참조 확장)와 규칙이 기각한 후보를 표시. 데모 3장면(바목 함정 · 법마다 다른 판단 · 시행령이 채운 숫자) 재현.	완료
평가	① 검색 · ② 규칙 판정 · ③ 최종 빌드를 따로 측정. dev 11건(만들면서 본 케이스) + held-out 11건(미리 따로 써 둔 케이스). 결과가 바뀌면 스냅샷 테스트가 알려 줌.	완료
평가셋 확장	dev 15건 목표 중 11건, held-out v2 미작성.	남음
OpenAI 실험	OpenAI 임베딩·LLM 특성 추출로는 아직 한 번도 측정하지 않음(키 없음).	남음

3 현재 성능

로컬 해싱 임베딩 · 키워드 특성 추출 · 청크 1,736개 기준입니다. Docling 전환 전후로 수치는 같습니다.

지표	무엇을 보나	dev (11)	held-out (11)
① 검색 Hit@3 — 설명 그대로	서비스 설명을 그대로 검색했을 때 정답 조문이 상위 3개 안에 드는 비율	0.28	0.07
① 검색 Hit@3 — 특성 쿼리	특성을 법률 용어 쿼리로 바꿨을 때	0.83	0.80
① 후보 재현율 (평균 후보 수)	실제 파이프라인 후보에 정답 조문이 들어간 비율	0.89 (26.8)	0.87 (27.2)
② 규칙 판정 정확도	검색 없이 규칙만으로 판정했을 때	1.00	0.69
③ 최종 빌드 정확도	RAG 후보 → 규칙 검증까지 거친 결과	1.00	0.61
③ 케이스 완전 일치	한 케이스의 점검이 모두 맞은 비율	1.00	0.36

- 쿼리를 법률 용어로 바꾸면 검색이 크게 좋아진다(held-out 0.07 → 0.80). 개인정보 보호법·신용정보법 청크 1,174개가 섞여 있어서 일상어 설명은 엉뚱한 조문에 붙는다.
- dev 1.00은 실력이 아니다. 규칙을 만들며 본 케이스라서다. 진짜 실력은 held-out ③ 0.61.
- 평가셋이 작다. 검색 정답 조문이 dev 18개, held-out 15개뿐이라 정답 1개 차이가 0.06~0.07이다. 내일 실험 전에 검색 정답을 늘려야 비교가 의미 있다.

4 어디서 틀리나 — held-out에서 틀린 점검 14개

원인	개수	케이스와 이유	내일 담당
검색	3	H02 발전소 자동 제어 — 영역 쿼리 끝의 공통 문구("고영향 인공지능 영역")가 짧은 가목 조문("에너지의 공급")보다 제33조·제35조를 위로 끌어올림	B (쿼리 문구) · C
특성 추출	8	H01 "자동으로 판독", H03 "스스로 결정", H08 "사람 검토 없이 산출", H07 "실제 사람 목소리처럼" 같은 표현을 키워드 추출기가 못 읽음	B (키워드 · LLM 추출기)
규칙 범위	3	H06 시행령 제23조④ 내부 업무 예외를 판정에 안 씀 · H09 설명 속 이용자 수(150만)를 시행령 기준과 비교하지 않음	B (규칙) · A (정답 확인)

이 실패를 고치면 held-out이 '이미 본 데이터'가 됩니다. 그래서 고치기 전에 held-out v2를 먼저 쓰고, 지금 held-out(v1)은 개발용으로 옮깁니다.

5 구현하고자 하는 것

내일(10월 9일) — 네 명 모두 RAG 한 단계씩 실험해서 가장 좋은 설정 찾기

#	목표	끝났다고 보는 기준
1	held-out v2 작성 — 실패를 고치기 전에 새 시험지를 먼저 만든다	11건, PM과 2인 검토 후 커밋
2	검색 정답 늘리기 — 검색만 채점하는 질의 세트(정답 조문만 적은 문장 20~30개)	정답 1개 차이가 0.03 이하가 되도록
3	RAG 단계별 실험 — 임베딩 · 검색 설정 · 쿼리 변환 · 청크 표현을 한 번에 하나씩 바꿔 비교	1인당 실험 2개 이상, 실험 기록표에 숫자와 이유
4	실패 수정 — 위 14개 점검을 원인별로 수정	held-out v1을 옮긴 개발용 세트에서 개선
5	최종 조합 확정 — 단계별 1등을 합친 조합을 held-out v2로 한 번만 측정	발표용 결과표 (전 → 후)

다음 단계 — 발표에서만 소개

- 다음 2차 빌드 `--validate`: 구현 상태를 입력받아 ERROR / PASS 판정
- 다음 Plain 모드: 비개발자용 쉬운 설명(LLM 표현 단계)
- 다음 리포트 Export
- 다음 정부 고영향 AI 판단 가이드라인 원문·장관 고시 추가 → 남은 EXTERNAL 해소

6 RAG 용어 — 내일 실험에서 쓰는 말

청크	검색 단위로 자른 문서 조각. 우리는 고정 길이가 아니라 조·항·호·목, 절 단위로 자르고 앞에 상위 조문 제목을 붙인다.
임베딩	문장을 숫자 벡터로 바꾸는 것. 뜻이 비슷하면 벡터도 가깝다. 로컬 해싱은 글자 조각이 겹치지만 보고, OpenAI 임베딩은 의미를 본다.
벡터 DB	청크 벡터를 저장하고, 쿼리 벡터와 가까운 순서로 꺼내 주는 저장소. 우리는 Chroma를 쓴다.
top-k	쿼리 하나당 가져오는 청크 수. 늘리면 정답이 들어올 확률은 오르지만 규칙이 검토할 후보도 늘어난다.
쿼리 변환	사용자 문장을 검색에 유리한 말로 바꾸는 것. "채용 점수 추천"을 "채용 지원자 판단 평가 개인의 권리 의무"처럼 법률 용어로 옮긴다.
참조 확장	검색으로 찾은 조문이 가리키는 상위 조문·참조 조문을 후보에 더하는 것.
Hit@3	정답 조문이 검색 상위 3개 안에 들어간 비율.
후보 재현율	파이프라인이 규칙에 넘긴 후보 전체에 정답 조문이 들어간 비율. 평균 후보 수와 같이 봐야 한다.
dev / held-out	dev는 보면서 고치는 연습 문제, held-out은 마지막에 한 번만 푸는 시험지. 시험지를 보고 고치면 점수가 부풀려진다(데이터 누수).